

Desenho de Projeto para Ciência de Dados

Aulas Semana 3

Scientific Writing – II

Data Science Methodology: CRISP-DM

Ano Letivo
2025/2026

Nota geral: os slides de apoio às aulas podem estar escritos em português ou em inglês.

Conteúdo da aula

1. Escrita científica (continuação):
 - regras de escrita
2. Metodologia e o ciclo de processo CRISP-DM
 - O ciclo de dados
 - Modelo de processo para tratamento de dados

MCD @ Iscte

4

4

***If you torture the data long enough, it
will confess.***

— Ronald H. Coase, Essays on
Economics and Economists

5



Escrita científica

Algumas regras escritas e não escritas

MCD @ Iscte 6

6



Normas usuais

- Não usar a 1ª pessoa (*Para isso, eu desenvolvi...*) nem pessoas singulares
- Usar a primeira pessoa do plural (*Para isso, desenvolvemos ...*) ou o impessoal (*Para isso, foi desenvolvido ...*)
- A dissertação é um documento do tipo livro, ou seja, uma narrativa com princípio, meio e fim (não um relatório técnico): não deixe espaços em branco no meio ou no resto de uma página, com exceção da última página de um capítulo.
- Todos os capítulos devem **iniciar numa página ímpar**. Se necessário, deixe uma página em branco. O mesmo para os apêndices, resumo e abstract.

MCD @ Iscte 7

7

Normas usuais

- Em Ciência de Dados, os dados são a peça central, pelo que devem ser bem descritos. Para isso, serão necessárias visualizações: **não coloque uma imagem longe do local no texto** onde ela está a ser mencionada/explicada pela primeira vez.
- Apenas figuras/tabelas que são mencionadas no texto devem figurar no corpo principal. As restantes, se relevantes, devem ser incluídas num apêndice.
- Os apêndices são numerados por letras maiúsculas seguindo a ordem alfabética e devem começar com uma introdução/descrição breve ao seu conteúdo.
- Para outros detalhes importantes, como número de páginas e numeração das mesmas, ver no site do Iscte dedicado à submissão de provas.

MCD @ Iscte

8

8

Iscte: normas e modelos docx e LaTeX

- Página no *site* do Iscte com normas
<https://www.iscte-iul.pt/conteudos/estudantes/informacao-academica/percurso-academico/area-mestrado/926/entrega-de-dissertacao-ou-trabalho-de-projeto>
- Nota Importante: a segunda capa da Dissertação deve conter os logos da IBS e da Ista e indicar o Departamento de Métodos Quantitativos para a Gestão e Economia e o Departamento de Ciências e Tecnologias da Informação abaixo da linha horizontal.
- Para quem usar o LaTeX, deve usar o template no link seguinte, que está completamente preparado para o formato indicado no MCD:
https://iscteiul365-my.sharepoint.com/:u:/g/personal/amcaa1_iscte-iul_pt/EQEIUUV7eqRGq8ta9dIA8fcB94dnDnc-F3z2GAYIFRztfq?e=ySMQxP

MCD @ Iscte

9

9


CRISP-DM

A metodologia CRISP-DM para a Ciência de Dados
(revisão)

10


Fases importantes de tratamento de dados

- Mundo real
 - Dados não tratados (*raw data*)
 - Preparação dos dados
 - Exploração sobre os dados
 - Modelação
 - Comunicação
 - Decisões e implantação de Produto
- ... e estamos de volta ao mundo real



11

Benefícios da introdução de Ciência de Dados nas empresas




Source: Provost, F. Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking. O'Reilly, 2013.

DDD (Data-Driven Decisions) são tomadas com base em resultados obtidos de uma forma automática.

É necessário desenhar sistemas centrados no humano (**human-centric**) e, sempre que possível, colocar a dimensão humana no sistema (**human-in-the-loop**).

12

Decisão guiada por dados



Adaptado de ©2012 Han, Kamber and Pei

13

Como desenvolver um processo de ciência de dados?


- Os dados são valiosos, mas os dados também “podem dizer” o que quisermos! Podem sofrer de bias, desigualdades, ...

É necessário um modelo faseado para guiar a construção de uma decisão baseada em dados (data-driven)

- Na prática, procura-se um sistema ou “solução” analítica baseada numa análise cuidada e sistémica, passível de ser avaliada ou replicada mais tarde.
- O raciocínio estruturado realça o valor e a verdade dos dados, providenciando o necessário apoio à tomada de decisão.
- O aspeto humano para e na extração de conhecimento em dados deve ser realçado. Mas o humano traz consigo a parcialidade da perspetiva:

14

Importante: ética em Ciência de Dados




- É necessário, no mínimo, sistematizar um processo de tratamento de dados ao longo de todo o ciclo de vida.
- Seria ideal criar um código deontológico.

16

Problema do Enviesamento (bias)

There are a wide range of potential causes of algorithmic bias




O humano é sempre fonte de parcialidade

Source: LisaBalboa.com

Aim to mitigate these biases as early on in the algorithmic development process as possible

17

Cross Industry Standard Process for Data Mining CRISP-DM




A Ciência de Dados baseia-se na
metodologia CRISP-DM
 para produzir os seus resultados.

Source: "CRISP-DM" *Wikipedia*,
 The Free Encyclopedia (accessed October 10, 2015).

18

Cross Industry Standard Process for Data Mining CRISP-DM



19

Problema do Enviesamento (bias)


Modelo utilizado em Ciência de Dados para guiar a construção de uma decisão baseada em dados replicável e auditável

- Relative costs of Type I and Type II errors on individuals & society not considered
- Equity of outcomes not examined as part of algorithmic development
- Algorithm aims to maximise resource efficiency without considering fairness of resource allocation

Source: LisaBalboa.com

Aim to mitigate these biases as early on in the algorithmic development process as possible

CRISP-DM



21

Problema do Bias

While it may not be possible to eliminate all sources of bias, with certain precautionary measures, some bias issues can be reduced. Here are some key messages that could aid ML developers in identifying potential sources of bias and help in avoiding the introduction of unwanted bias:

- CRISP-DM Domain Understanding
 - Incorporation of domain-specific knowledge is essential in defining and detecting bias to understand the structural relationships between various features in the dataset. Often, it helps to draw a structural diagram, illustrating various features of interest and their interdependencies. This can then help in identifying the sources of bias.
- CRISP-DM Data Understanding
 - It is also important to understand which features of the data are deemed sensitive based on the application. For example, age may be a sensitive feature in determining who gets a loan, but not necessarily in determining who gets a medical treatment. Furthermore, there may be proxy features that, although not thought to be sensitive features, may still encode sensitive information, rendering biased predictions.
- CRISP-DM Data Understanding
 - As far as possible, datasets used for analysis should be representative of the true population under consideration. Thus, care has to be taken in constructing representative datasets.

Adaptado de: ACM, acm.org (2021)

Ramya Srinivasan and Ajay Chander. 2021. Biases in AI Systems: A survey for practitioners. Queue 19, 2, Pages 10, (March-April 2021). <https://doi.org/10.1145/3466132.34661345>.

23

Problema do Bias

- CRISP-DM Data Preparation (Annotation)
 - Appropriate standards have to be laid out for annotating the data. Rules have to be defined so as to obtain consistent labels from annotators as much as possible.
- CRISP-DM Data Preparation (Selection)
 - Identifying all features that may be associated with the target feature of interest is important. Omitting variables that have dependencies with the target feature leads to a biased estimate.
- CRISP-DM Data Preparation (Leakage)
 - Features that are associated with both input and output can lead to biased estimates. In such cases, it is important to eliminate these sources of confounding biases by appropriate data conditioning and randomization strategies in selecting input

Adaptado de: ACM, acm.org (2021)

Ramya Srinivasan and Ajay Chander. 2021. Biases in AI Systems: A survey for practitioners. Queue 19, 2, Pages 10, (March-April 2021). <https://doi.org/10.1145/3466132.34661345>.

24

Problema do Bias

- CRISP-DM Data Modeling
 - Restricting data analysis to some truncated portions of the dataset can lead to unwanted selection bias. Thus, in choosing subsets of data for analysis, care must be taken not to introduce sample selection bias.
- CRISP-DM Evaluation
 - In validating the performance of a model such as in A/B testing, care has to be taken to guard against the introduction of sample treatment bias. In other words, in testing the performance of a model, the test conditions should not be restricted to a certain subset of the population (e.g., showing recommendation results to people of a certain locality only), as the results would be biased.


Adaptado de: ACM, acm.org (2021)

Ramya Srinivasan and Ajay Chander. 2021. Biases in AI Systems: A survey for practitioners. Queue 19, 2, Pages 10, (March-April 2021). <https://doi.org/10.1145/3466132.34661345>.

25

Exemplo de tarefas com uma aplicação concreta:

Uma universidade europeia quer implementar um sistema de previsão de desempenho académico para identificar estudantes em risco de reprovação ou abandono, com o objetivo de melhorar as taxas de sucesso e apoiar os alunos de forma proativa.




MCD @ Iscte

26

26

Previsão de Desempenho Académico de Estudantes numa Universidade

Business Understanding




CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024

- **Definir Objetivos de Negócio:** O objetivo principal é compreender o que afeta a aprovação e o abandono escolar, para futuramente garantir que os estudantes recebam o suporte necessário.
- **Estabelecer Critérios de Sucesso:** Definir métricas como o aumento da taxa de aprovação, diminuição da taxa de abandono e número de estudantes que melhoraram o desempenho após intervenções.
- **Plano de Projeto:** Estabelecer cronogramas, equipas responsáveis e dados necessários. Definir um calendário para recolha de dados, desenvolvimento do modelo e implementação de ações baseadas nos resultados.

27

27

Data Understanding




CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024

- **Recolha de Dados Iniciais:** Recolher dados - registos de matrícula, notas anteriores, frequência às aulas, participação em atividades extracurriculares, interações com a plataforma de e-learning e dados socioeconómicos (caso permitido).
- **Descrever os Dados:** Analisar a quantidade e os tipos de dados. Identificar variáveis importantes, como a média de notas, assiduidade e a utilização de recursos de apoio.
- **Exploração nos Dados:** Analisar correlações e padrões iniciais entre as variáveis, como por exemplo, a relação entre presença nas aulas e média de notas. Identificar aspetos que possam ser comuns nos alunos que têm um desempenho inferior.
- **Verificação da Qualidade dos Dados:** Detetar valores em falta, inconsistências, ou duplicados. Por exemplo, verificar se há notas em falta ou se a frequência às aulas foi registada corretamente.

Se necessário, criar/afinar os objetivos e as questões de investigação em função dos dados disponíveis

29

Data Preparation




CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024

- **Limpeza dos Dados:** Preencher valores em falta (por exemplo, estimar a quantidade de horas de uma disciplina com base nas outras e no horário completo), eliminar duplicados e escalar variáveis coerentemente (como escalas de notas diferentes).
- **Transformação dos Dados:** Normalizar variáveis numéricas e codificar variáveis categóricas, como a área de estudo ou o tipo de apoio recebido.
- **Engenharia de Variáveis:** Criar novas variáveis, como a "Média de Notas Semestral" ou "Interações Semanais na Plataforma de E-learning". Estas variáveis podem fornecer um contexto adicional sobre o comportamento dos estudantes.
- **Seleção de Variáveis:** Selecionar as variáveis que mais contribuem para a previsão, utilizando técnicas como análise de correlação, importância de variáveis em árvores de decisão ou redução de dimensionalidade.

31

31

Modeling



CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024


- **Seleção de Técnicas de Modelação:** Escolher algoritmos apropriados, como regressão linear, árvores de decisão, *random forest* ou modelos baseados em redes neurais.
- **Treinar os modelos:** Dividir os dados em conjuntos de treino e teste e treinar os modelos.
- **Avaliação dos Modelos:** Utilizar métricas como a precisão (*accuracy*), a área sob a curva ROC (AUC-ROC), a *F1-Score* e a matriz de confusão para avaliar o desempenho do modelo no conjunto de teste.
- **Comparação de Modelos:** Comparar diferentes modelos e selecionar o que apresenta melhores resultados com base nos critérios definidos (por exemplo, um modelo com alto *recall* para identificar a maioria dos estudantes em risco).

Se necessário, melhorar a preparação de dados ou, mesmo, recolher outros/novos dados

33

33

Evaluation




CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024

- **Revisão de Desempenho do Modelo:** Avaliar se o modelo satisfaz os critérios de sucesso. Validar se a previsão consegue identificar a tempo os alunos que necessitam de apoio.
- **Validação com os Stakeholders:** Apresentar os resultados aos professores e conselheiros para verificar se o modelo se adequa ao contexto pedagógico. Discutir os casos identificados e planejar ações de intervenção.
- **Documentação dos Resultados:** Registrar todos os *insights* e apresentar um relatório final com as conclusões e recomendações para o processo de intervenção.

35

35

Deployment




CRISP-DM aplicado.
Source: Ana Rita Peixoto,
ICD, Iscte, 2024

- **Implementar o Modelo:** Integrar o modelo no sistema de gestão académica para monitorizar o desempenho dos estudantes em tempo real. Gerar relatórios periódicos para identificar alunos em risco.
- **Definir Planos de Intervenção:** Desenvolver ações específicas, como tutorias, workshops, ou sessões de orientação para os estudantes identificados.
- **Monitorização e Manutenção do Modelo:** Acompanhar a performance do modelo ao longo do tempo. Atualizar o modelo com novos dados no final de cada semestre para garantir a sua validade.
- **Comunicação dos Resultados:** Partilhar os resultados e melhorias alcançadas com os departamentos envolvidos – pedagógico e apoio ao estudante - para ajustar estratégias educacionais conforme necessário.

37

37

Estrutura geral de Dissertação: vista em CD

- 
- Capa (com Título e Atores principais)
 - Resumo e Abstract
 - Listas: Figuras, Tabelas, Acrónimos
 - 1. Introdução → • Business Understanding
 - 2. Revisão da Literatura/Estado da arte → • Data understanding
 - 3. Capítulos centrais → • Modeling
 - 4. Discussão de Resultados → • Evaluation
 - 5. Conclusões → • Deployment
 - Bibliografia
 - Apêndices

MCD @ Iscte

39

39

CRISP-DM e metodologias Agile

- CRISP-DM:
Ver <https://www.datascience-pm.com/crisp-dm-2/>
- Agile Philosophy
*Conceptually Agile and data science are a great match. Most notably, both Agile and data science emphasize the same underlying concept that **you build something**, you **learn from what you delivered**, and then you **improve it based on what you learn***
em <https://www.datascience-pm.com/agile-data-science/>

MCD @ Iscte

41

41



E chegámos ao fim da aula de hoje

MCD @ Iscte

42

42



Pontos importantes da aula Wrap up

1. Escrita científica:
 - regras de escrita
2. Metodologia e o ciclo de processo CRISP-DM (revisão)
 - O problema do enviesamento (não intencional)
 - Ligação com o esquema de uma dissertação

MCD @ Iscte

43

43